

Feature engineering — validé sur données réelles (éCO2mix national, 2012–2026)

Reprise du feature engineering directement sur le fichier réel


`eco2mix-national-cons-def.csv` (508 320 lignes → **254 158 points** après passage au pas natif du réalisé). Ce document remplace l'analyse synthétique par des mesures sur l'historique complet et documente **trois corrections** apportées au code.

1. Ce que le fichier réel impose


Constat (mesuré)	Conséquence
Réalisé publié au pas de 30 min (1 ligne sur 2 vide en 15 min)	pipeline conscient de la cadence ; on retire les lignes vides plutôt que d'imputer 50 % de la cible
28 points seulement en trou court (14 trous de 90 min) sur 14 ans	imputation linéaire ≤ 1 h suffisante ; 0 trou long
Changements d'heure présents (ex. 26/03/2023 → 46 pas au lieu de 48)	grille tz-aware + Fourier calendaire (voir §3)
Consommation réelle : 29 → 102 GW , moyenne 53 GW	pas de valeur aberrante ; bornes physiques respectées

2. La structure saisonnière, mesurée sur le réel


Profil journalier par jour de semaine — la double bosse matin/soir et le décrochage du week-end sont nets :



Structure jointe heure $\times$ jour :



Cycle annuel / **thermosensibilité** (remontée hivernale, creux estival) :



3. Trois corrections apportées au feature engineering

3.1 Cadence-awareness (bug de période)

L'ancien code fixait 96 pas/jour et un pas de 15 min en dur. Sur le réalisé à 30 min, les lags, la grille et surtout les périodes de Fourier étaient faux.

Tout dérive désormais de `settings.freq` : `steps_per_day` = 48 à 30 min, 96 à 15 min (bascule via `ANOM_FREQ`).

3.2 Termes de Fourier en phase calendaire (correction majeure)


L'ancienne version encodait les cycles sur un **index physique** (`minutes//15`).

Deux défauts : la période journalière était erronée à 30 min, et la phase

dérivait par rapport à l'horloge locale à chaque changement d'heure. La nouvelle version cale la phase sur le calendrier local :

- journalier : `quarter_of_day / steps_per_day`
- hebdo : `(dow * steps_per_day + quarter_of_day) / (7 * steps_per_day)`
- annuel : `(doy - 1) / 365.25`

Vérification sur le réel : `fourier_day_sin1` est **constant à heure fixe** d'un jour à l'autre (période = 1 jour exact), et reste verrouillé sur l'horloge à travers les transitions DST.




3.3 Bug d'overflow Int8

L'index intra-journée (`hour * 60 + minute`) débordait le type `Int8` de polars (max 127) → valeurs négatives. Corrigé par un cast `Int32`. Ce bug corrompait la feature même en 15 min.


4. Effet sur la désaisonnalisation et le modèle

La baseline B1 (écart à J-7) divise fortement l'écart-type — la structure déterministe est bien retirée :



Modèle de contrôle (HistGradientBoosting sur les 33 features, aucune fuite) :

MAE 1039 MW en validation (~2 % de la charge moyenne), contre 1376 MW avec l'ancien Fourier bogué — la correction améliore réellement la reconstruction du déterministe. Le résidu, seuillé de façon robuste, signale **0,67 %** des points (taux sain, pas un détecteur qui crie en permanence) :



5. Contrat de sortie (inchangé)

52 colonnes : `date_heure`, `consommation`, `exogènes`, `calendrier`

(`dow`, `quarter_of_day`, `fériés`, `vacances`, `ponts`, `is_dst`), `fourier_*`

(14 termes, phase calendaire), lags/rolling `consommation_*`, `baselines`

`resid_b1` / `resid_b2`, drapeaux qualité `is_missing` / `is_imputed`.

6. Reproduire

```
1 # place le CSV puis :  
2 export ANOM_RAW_CSV_PATH=data/eco2mix-national-cons-def.csv  
3 uv run pytest -q # 14 tests  
4 uv run python -m src.models.train_model # entraîne sur le réel
```

Pistes non retenues à ce stade (volontairement, périmètre modèle simple) :

météo exogène (degré-jours Open-Meteo) pour absorber la thermosensibilité

résiduelle, et décomposition MSTL adaptative — voir `learning_saisonnalité.md`.